Agente Roda Liso para aplicação assistida de configurações gráficas em jogos.

Felipe Antonio, Gustavo de Almeida, Keven Rodrigues, Luan Ferreira [1]

Me. Gabriel Lara Baptista

Resumo

A diversidade de componentes de computadores pessoais e a dificuldade de relacionar especificações, requisitos de jogos e benchmarks ao desempenho observado motivam o estudo de ferramentas de apoio ao ajuste gráfico. Dados recentes sobre o mercado de jogos contextualizam a relevância do setor, enquanto pesquisas sobre hardware, telemetria, recuperação de informações e diagnóstico orientam a análise do problema, com fundamentação posterior ao desenvolvimento do protótipo, utilizada como referência analítica. Este trabalho tem como objetivo avaliar o agente do Roda Liso, que monitora a taxa de quadros por segundo (FPS) e recomenda presets gráficos predefinidos quando o desempenho permanece abaixo da meta escolhida pelo usuário. A fundamentação teórica apoia-se em oito trabalhos selecionados sobre mercado de jogos, predição de desempenho, telemetria, recuperação de informação e diagnóstico assistido. Na implementação analisada, regras em Python selecionam o preset, e um modelo de linguagem redige uma explicação breve; a aplicação depende de confirmação e prevê restauração por backup. A pesquisa aplicada e exploratória contempla a verificação funcional e a comparação do FPS antes e depois do ajuste, priorizando The Witcher 3 em um computador com Intel Core i5-4590, GeForce GTX 950, 16 GB de RAM DDR3 e Windows 10. Também serão registradas alterações visuais, falhas e o funcionamento dos mecanismos de confirmação e reversão. Nesta etapa, apresentam-se a fundamentação e o planejamento da avaliação, sem resultados experimentais. A contribuição pretendida é examinar o efeito e a segurança operacional da aplicação assistida de presets nas condições testadas, com conclusões restritas ao cenário avaliado.

Palavras-chave: Desempenho em jogos. Hardware de computadores. Configurações gráficas. Taxa de quadros. Sistemas de apoio à decisão.

Abstract

The diversity of personal computer components and the difficulty of relating specifications, game requirements, and benchmarks to observed performance motivate the study of tools that assist graphics configuration. Recent data on the gaming market provide context for the sector's relevance, while research into hardware, telemetry, information retrieval, and diagnostics guides the analysis of the problem; it is worth noting that this theoretical framework was developed after the prototype and serves as an analytical reference rather than a basis for implementation. This study aims to evaluate the Roda Liso agent, which monitors frames per second (FPS) and recommends predefined graphics presets when performance remains below a user-selected target. The theoretical framework is based on eight selected studies concerning the gaming market, performance prediction, telemetry, information retrieval, and assisted diagnosis. In the evaluated implementation, Python rules select the preset, and a language model writes a brief explanation; applying changes requires user confirmation and allows restoration from a backup. This applied, exploratory study plans functional verification and a before-and-after FPS comparison, focusing on The Witcher 3 on a desktop with an Intel Core i5-4590, GeForce GTX 950, 16 GB of DDR3 RAM, and Windows 10. Visual changes, failures, confirmation, and restoration will also be recorded. At this stage, the theoretical framework and evaluation plan are presented, without experimental results. The intended

[1] Faculdade Engenheiro Salvador Arena, Centro Educacional da Fundação Salvador Arena, Estrada dos Alvarengas, 4001 - São Bernardo do Campo - SP

contribution is to examine the effects and operational safeguards of assisted preset application under the tested conditions, with conclusions limited to the evaluated scenario.

Keywords: Gaming performance. Computer hardware. Graphics settings. Frame rate. Decision-support systems.

1 Introdução

A expansão dos jogos digitais reúne transformações tecnológicas, formas de distribuição e modelos de negócio que ampliaram sua presença no entretenimento. Em uma análise publicada em 2021, Pashkov descreve a contribuição da distribuição digital, da diversificação das plataformas e de modelos como o free-to-play para a expansão do setor. O autor também destaca a modularidade dos computadores pessoais, cujos componentes podem ser combinados e substituídos. Esse contexto histórico ajuda a situar a relevância de soluções voltadas ao uso de jogos em PCs, sem pressupor que todos os jogadores disponham de equipamentos com capacidades semelhantes (Pashkov, 2021).

Como complemento à literatura acadêmica, a Newzoo informa que a receita global do mercado de jogos atingiu US$ 201,6 bilhões em 2025, crescimento de 9,1% em relação a 2024. Dentro desse total, o segmento de jogos para PC correspondeu a US$ 43,6 bilhões e apresentou crescimento anual de 12%, segundo a atualização divulgada em junho de 2026. Esses indicadores dimensionam a atividade econômica do setor e a presença do PC nesse mercado, mas não quantificam a parcela de jogadores com dificuldades técnicas nem demonstram demanda específica pelo Roda Liso (Buijsman, 2026).

No computador pessoal, compreender a relação entre especificações e desempenho exige considerar diferentes componentes e a aplicação executada. Mankodi et al. (2020) mostram que as características de processador e memória apresentam relações distintas com cargas de trabalho predominantemente computacionais ou intensivas em acesso à memória. No contexto dos jogos, Zhang et al. (2025) identificam a influência conjunta de características do equipamento e do próprio jogo sobre a taxa de quadros. Assim, a leitura isolada do nome de um processador, da capacidade de memória ou do modelo da placa de vídeo oferece informação insuficiente para antecipar todas as condições de execução.

Essa diversidade também impõe uma dificuldade de interpretação ao usuário. Gerra e Joseph (2026) descrevem a dispersão de informações sobre hardware entre especificações, benchmarks e avaliações de comunidades. Zhang et al. (2025), por sua vez, discutem limitações das listas de requisitos mínimos e recomendados e das indicações binárias sobre a execução de jogos. Nesse cenário, reconhecer o nome de um componente, verificar a compatibilidade do jogo e estimar como ele funcionará em determinada qualidade gráfica são tarefas diferentes. Um computador capaz de iniciar um jogo pode ainda demandar alterações para se aproximar da taxa de quadros desejada.

Essa diferença pode ser ilustrada pelo papel de cada componente: a CPU executa parte da lógica e das tarefas de processamento do jogo; a GPU participa principalmente da produção gráfica; e a memória RAM armazena dados temporários utilizados durante a execução. A influência de cada recurso depende, porém, do jogo, da resolução, das opções visuais e das condições do sistema. Por isso, saber apenas que um computador possui 16 GB de RAM ou determinada placa de vídeo não equivale a conhecer o FPS que será obtido. Interpretar as especificações em conjunto, e não como uma lista isolada de números e siglas, é uma necessidade informacional que orienta a proposta de assistência do Roda Liso (Mankodi et al., 2020; Zhang et al., 2025).

O problema abordado neste trabalho é o apoio à escolha de configurações gráficas quando o desempenho observado permanece abaixo da meta definida pelo jogador. A questão de pesquisa é: em que medida a aplicação assistida de presets gráficos, selecionados por regras a partir do FPS medido, altera o desempenho do jogo no computador avaliado? A investigação considera tanto o resultado da alteração quanto o funcionamento da recomendação, da confirmação do usuário e da restauração da configuração anterior.

O objetivo geral é avaliar o agente do Roda Liso que monitora o desempenho de jogos e recomenda a aplicação de presets gráficos predefinidos. Os objetivos específicos são verificar o acionamento da recomendação diante de FPS persistentemente abaixo da meta; conferir a correspondência entre a regra de seleção, o preset indicado e a explicação apresentada; verificar os mecanismos de confirmação, backup e reversão; e comparar o FPS e as alterações visuais antes e depois da aplicação do preset, sob condições controladas.

A justificativa prática está em investigar uma forma de auxiliar o jogador a ajustar o jogo no equipamento de que já dispõe. A hipótese de trabalho é que a aplicação de um preset que reduza a carga gráfica possa elevar o FPS nas condições avaliadas, com possíveis perdas de qualidade visual. Essa hipótese será verificada experimentalmente: a seleção de um preset não garante aumento de desempenho, alcance da meta ou melhoria da experiência percebida.

O recorte da pesquisa é o agente de monitoramento e aplicação assistida de presets, e não uma avaliação integral de todas as funções do Roda Liso. O estudo será conduzido em um computador de mesa com Intel Core i5-4590, NVIDIA GeForce GTX 950, 16 GB de RAM DDR3 e Windows 10, priorizando The Witcher 3. A avaliação abrangerá o funcionamento do agente e uma comparação antes e depois da alteração gráfica. As conclusões ficarão restritas ao equipamento, ao jogo e aos cenários testados. A seção 2 apresenta os conceitos e trabalhos relacionados; a seção 3 descreve a metodologia de avaliação. Os resultados serão apresentados após a realização dos testes.

2 Referencial teórico

O referencial reúne oito trabalhos selecionados sobre a evolução do mercado de jogos, a relação entre hardware e desempenho, a telemetria, a interpretação de informações técnicas, a recuperação de conhecimento e o diagnóstico assistido. Além deles, utilizam-se levantamentos setoriais e documentação técnica para contextualização. A revisão permite comparar abordagens existentes com o escopo delimitado do Roda Liso. A implementação avaliada foi desenvolvida independentemente desses estudos; assim, métodos apresentados na literatura não são atribuídos ao processo de construção do protótipo.

2.1 Mercado de jogos e diversidade dos computadores pessoais

Pashkov (2021) analisa a evolução do mercado de jogos a partir de mudanças nas plataformas, na distribuição e nas formas de monetização. Sua discussão mostra que a expansão do setor envolve experiências e públicos distintos, incluindo jogos em computadores, consoles e dispositivos móveis. Para o presente trabalho, essa análise oferece uma contextualização econômica e tecnológica. Os dados e as tendências descritos pelo autor correspondem ao período de sua pesquisa e não são adotados como estimativas atuais do mercado ou como caracterização do público brasileiro.

No segmento de computadores pessoais, a possibilidade de combinar componentes amplia a variedade de configurações. Essa flexibilidade exige distinguir a compatibilidade entre peças da capacidade do conjunto de executar uma determinada carga de trabalho. Lopez, Guynn e Lu (2018) estudam a previsão de resultados de benchmarks com base em características da configuração, enquanto Mankodi et al. (2020) analisam como diferentes aplicações se comportam em sistemas físicos e simulados. Ambos evidenciam a necessidade de relacionar o equipamento à tarefa executada, em vez de pressupor uma classificação única de desempenho válida para qualquer uso.

A diversidade dos equipamentos também pode ser observada na Steam Hardware & Software Survey, levantamento mensal da Valve com participação opcional e anônima. A edição de setembro de 2026 apresenta distribuições de memória RAM, placas de vídeo, processadores e sistemas operacionais. Esses dados descrevem os participantes do levantamento e não são utilizados neste trabalho para definir um computador médio brasileiro ou justificar a representatividade do equipamento de teste (Valve, 2026).

Na amostra da Steam referente a setembro de 2026, considerando os participantes que utilizavam Windows, configurações com 16 GB de RAM representavam 37,60%, enquanto aquelas com 32 GB correspondiam a 43,28% (Valve, 2026). Os percentuais ilustram a coexistência de capacidades de memória distintas entre os respondentes, mas não informam, isoladamente, a adequação de cada computador a um jogo. Também não constituem amostra representativa de todos os jogadores ou do mercado brasileiro.
A interpretação dessa variedade constitui parte do problema enfrentado pelo usuário. No GameSpec Advisor, Gerra e Joseph (2026) propõem reunir dados técnicos, avaliações e análise de compatibilidade para apoiar a escolha de componentes. A motivação apresentada pelos autores é a fragmentação das informações disponíveis e a dificuldade de convertê-las em uma decisão. No Roda Liso, essa preocupação é delimitada ao ajuste de um jogo em um computador já existente. O interesse está em avaliar uma intervenção sobre as configurações gráficas, sem incluir a recomendação de compra de hardware no experimento, considerando usuários cujo FPS observado permanece abaixo da meta desejada no equipamento disponível.

2.2 Relação entre configuração e desempenho computacional

Benchmarks permitem avaliar sistemas por meio de cargas de trabalho definidas e resultados comparáveis. Lopez, Guynn e Lu (2018) utilizam dados dos conjuntos SPEC CPU2006 e SPEC CPU2017 para estimar pontuações a partir de características dos computadores. O estudo combina análise de componentes principais, utilizada na análise dos dados, e múltiplas redes neurais. A separação das informações por tipo de benchmark integra o método, pois diferentes testes possuem escalas e comportamentos próprios.

A documentação oficial da SPEC esclarece que o CPU2017 avalia desempenho computacional intensivo, envolvendo processador, hierarquia de memória e compiladores, e não foi projetado para avaliar o subsistema gráfico. A própria organização ressalta que benchmarks padronizados não substituem a avaliação da aplicação de interesse. Essa delimitação sustenta a distinção entre pontuações do SPEC e FPS observado em jogos (SPEC, 2024).

A contribuição desse trabalho para a discussão do Roda Liso está na relação entre configuração, carga de trabalho e medida de desempenho. Seus resultados dizem respeito aos benchmarks estudados e não constituem uma estimativa de FPS para os jogos deste projeto. Da mesma forma, a existência de um modelo capaz de prever pontuações em uma base conhecida não demonstra, por si só, que o mesmo desempenho preditivo será mantido em equipamentos ou aplicações diferentes (Lopez; Guynn; Lu, 2018).

Mankodi et al. (2020) comparam quatorze modelos de aprendizado de máquina utilizando aplicações com diferentes padrões de computação e acesso a dados. Os autores observam relações não lineares entre características do hardware e desempenho, além de diferenças entre os resultados obtidos com sistemas simulados e físicos. Essa constatação reforça a necessidade de considerar as condições de execução e limita interpretações que atribuam o desempenho de todo o sistema a uma única especificação.

Para o Roda Liso, a diversidade documentada nesses estudos justifica avaliar o comportamento efetivamente observado no jogo. O agente analisado não treina um modelo de previsão de desempenho a partir de especificações. Sua intervenção utiliza o FPS medido, a meta escolhida e a qualidade gráfica identificada para selecionar um preset existente. A comparação experimental mantém o mesmo computador nas duas condições, permitindo examinar a alteração gráfica sem confundi-la com uma troca de equipamento.
Yun et al. (2018) estudam a predição de desempenho em GPUs móveis Adreno e controlam a influência de DVFS e throttling nas medições. O estudo destaca a importância das condições de execução, mas não valida o aquecimento de dez minutos em um computador de mesa. Esse período integra o protocolo proposto pelo grupo e será confirmado no piloto, conforme a seção 3.7.

2.3 Taxa de quadros e experiência técnica em jogos

A taxa de quadros por segundo, ou FPS, representa a quantidade de quadros apresentada por unidade de tempo. Zhang et al. (2025) investigam a relação entre desempenho técnico e experiência em jogos utilizando uma base de telemetria com 100 mil usuários, 835 jogos e registros de 224 países e regiões. O estudo considera características dos dispositivos e dos jogos e propõe um modelo de aprendizado federado para prever distribuições de FPS. A diversidade da base permite discutir o desempenho como resultado de múltiplos fatores, em vez de tratá-lo como propriedade isolada de um componente.
Zhang et al. (2025) discutem que a média de FPS não descreve integralmente as oscilações durante a execução. O estudo considera também o indicador "95% FPS Floor" ("Low 5th FPS"), relacionado à parte inferior da distribuição das taxas de quadros. A distribuição dos valores e os períodos de desempenho reduzido oferecem informações adicionais sobre a regularidade da apresentação dos quadros. Isso não estabelece uma métrica universalmente superior para todos os jogos e cenários. A experiência do jogador envolve ainda aspectos que ultrapassam o desempenho técnico; uma variação de FPS não deve ser interpretada automaticamente como medida completa de satisfação.

Neste estudo, o FPS calculado em janelas de aproximadamente dois segundos será usado como indicador operacional para o acionamento do agente. A comparação entre configurações utilizará capturas contínuas de 180 segundos e o cálculo de FPS médio descrito na seção 3.6. A rotina atual do agente não calcula métricas como 1% low, cuja inclusão poderá ser considerada em trabalhos futuros. O protocolo também registrará alterações visuais e falhas de execução. Como não está prevista avaliação com participantes, os resultados não permitirão afirmar melhoria de satisfação ou usabilidade percebida. A meta padrão de 30 FPS é ajustável e não será tratada como limiar universal de qualidade fundamentado nos artigos.

2.4 Sistemas de apoio à escolha e trabalhos relacionados

O GameSpec Advisor aproxima-se do tema do Roda Liso por buscar tornar informações técnicas mais úteis à tomada de decisão do jogador. A proposta de Gerra e Joseph (2026) integra análise de configurações, regras de associação, análise de sentimentos e detecção de anomalias para apoiar recomendações de hardware. Essa abordagem reúne evidências sobre componentes e opiniões de usuários. Seu objeto principal é a composição e a avaliação de configurações de PC, enquanto a intervenção examinada no Roda Liso ocorre nas opções gráficas de um jogo em execução.

A dificuldade de compreender informações sobre componentes não se resolve necessariamente com a exibição de mais especificações. Para orientar uma escolha, é preciso relacionar o dado técnico à decisão concreta: identificar o que está sendo medido, explicar por que um ajuste pode influenciar o FPS e expor possíveis perdas de qualidade visual. No recorte avaliado, o Roda Liso apenas apresenta uma explicação breve associada à recomendação determinada por regras. Não foi realizado estudo com usuários que permita afirmar aprendizagem, aumento de conhecimento técnico ou melhoria de compreensão após utilizar a ferramenta.

Os trabalhos de Lopez, Guynn e Lu (2018) e Mankodi et al. (2020) concentram-se na previsão de desempenho computacional por modelos treinados com dados de configurações e cargas de trabalho. Zhang et al. (2025) aproximam essa linha de investigação do domínio dos jogos ao prever distribuições de FPS por telemetria e aprendizado federado. Esses estudos fornecem referências para compreender a complexidade da previsão, mas seus modelos e resultados não podem ser transferidos diretamente para a avaliação de presets do Roda Liso.

No protótipo avaliado, a seleção do preset é realizada por uma regra programada em Python. O modelo de linguagem participa da redação de uma explicação curta para o usuário, que decide se autoriza a aplicação. Dessa forma, a avaliação precisa conferir separadamente a seleção produzida pela regra, a correspondência da explicação com essa seleção e o efeito da configuração aplicada. A presença de um modelo de linguagem no fluxo não permite atribuir a ele a escolha do preset ou o eventual ganho de FPS.

2.5 Recuperação de informação e diagnóstico assistido na literatura

A geração aumentada por recuperação (Retrieval-Augmented Generation, RAG) combina um modelo de linguagem a informações recuperadas de fontes externas, de modo que a resposta possa considerar conteúdo específico da consulta. Essa abordagem interessa à discussão de assistência técnica porque a resposta adequada depende do problema relatado e das evidências disponíveis, e não apenas de uma recomendação genérica. Entretanto, citar estudos sobre RAG não significa que o Roda Liso tenha implementado buscas vetoriais, grafos de conhecimento ou recuperação automática de documentos.

Xu et al. (2024) propõem combinar RAG e grafos de conhecimento na resposta a perguntas de suporte ao cliente. Em vez de tratar registros históricos apenas como segmentos isolados de texto, a abordagem preserva relações dentro de cada ocorrência e entre diferentes ocorrências. Os autores relatam melhoria de 77,6% na métrica MRR em comparação à linha de base adotada, além de redução de 28,6% no tempo mediano de resolução no contexto de uso descrito. Tais resultados pertencem ao sistema e às condições desse estudo e não podem ser extrapolados para jogos ou para o Roda Liso.

Kapoor et al. (2026), em DQA: Diagnostic Question Answering for IT Support, abordam outra limitação: diálogos de diagnóstico exigem acumular evidências ao longo das interações, preservando hipóteses já examinadas. A proposta mantém um estado diagnóstico explícito e agrega casos recuperados por possíveis causas do problema. Em 150 cenários anônimos de suporte de TI, os autores relatam sucesso de 78,7%, em comparação a 41,3% de uma abordagem RAG de múltiplos turnos utilizada como referência. A relevância para o tema do TCC está no princípio de diagnóstico progressivo, em que informações sucessivas ajudam a distinguir causas possíveis, e não na reprodução da arquitetura ou de seus resultados. No contexto de desempenho em jogos, uma investigação futura poderia considerar diferentes hipóteses para FPS reduzido, como escolhas de qualidade gráfica, limites de processamento e condições específicas do jogo, verificando-as gradualmente. Essa possibilidade é uma perspectiva de pesquisa identificada na revisão. O agente avaliado emprega condições programadas e o FPS observado para escolher entre presets predefinidos; não executa diagnóstico com memória de hipóteses, não utiliza RAG e não foi avaliado pelos indicadores apresentados por Xu et al. (2024) ou Kapoor et al. (2026). Esses trabalhos ampliam o repertório de abordagens de diagnóstico e recuperação de informação e permitem discutir possibilidades futuras. No protótipo, confirmação, backup e reversão são mecanismos existentes a serem verificados pelo protocolo, sem que sua presença demonstre superioridade em relação às soluções revisadas.

2.6 Síntese comparativa dos oito trabalhos selecionados

O Quadro 1 sintetiza o objeto de cada trabalho selecionado e sua relação com o problema investigado. A comparação distingue a fundamentação do tema, o repertório de soluções encontradas na literatura e os mecanismos efetivamente presentes no agente avaliado.

Quadro 1 – Comparação dos trabalhos selecionados

Trabalho	Objeto e abordagem	Relação com o Roda Liso e limite
Pashkov (2021)	Análise do mercado de jogos, plataformas e modelos de distribuição.	Contextualiza a expansão e a diversidade do setor; não caracteriza os usuários do aplicativo.
Lopez, Guynn e Lu (2018)	Previsão de pontuações de benchmarks computacionais com múltiplas redes neurais.	Mostra a relação entre hardware, tarefa e métrica; não prevê FPS no protótipo.
Mankodi et al. (2020)	Comparação de modelos de aprendizado de máquina em sistemas e cargas de trabalho diversos.	Evidencia a influência conjunta dos componentes e da aplicação; modelos não foram incorporados.
Gerra e Joseph (2026)	GameSpec Advisor: apoio à escolha de configurações e componentes de PC.	Relaciona a fragmentação da informação à decisão do usuário; seu foco é escolha de hardware.
Zhang et al. (2025)	Telemetria global e aprendizado federado para prever distribuições de FPS.	Fundamenta a medição de desempenho e suas oscilações; previsão federada não foi implementada.
Xu et al. (2024)	RAG com grafos de conhecimento para suporte ao cliente.	Apresenta recuperação contextual e vínculos entre casos; não há RAG no agente testado.
Kapoor et al. (2026)	DQA: diagnóstico iterativo com estado persistente e hipóteses concorrentes.	Sugere perspectiva de diagnóstico progressivo; não integra o fluxo atual de presets.
Yun et al. (2018)	Predição em GPUs móveis Adreno, com controle da influência de DVFS e throttling.	Discute condições de medição; não valida o aquecimento nem foi implementado no agente.

Fonte: elaboração própria com base nos trabalhos mencionados (2018–2026).

Os oito estudos não descrevem um único produto equivalente ao Roda Liso: tratam de mercado, desempenho, escolha de componentes, telemetria e métodos de recuperação e diagnóstico. Em conjunto, reforçam a pertinência do problema de interpretação e tomada de decisão. A contribuição experimental deste TCC, contudo, permanece restrita a verificar o comportamento de um agente de aplicação assistida de presets, sem treinamento preditivo, recuperação de documentos ou diagnóstico conversacional.

2.7 Delimitação da contribuição e relação com a avaliação

A literatura selecionada sustenta quatro aspectos relacionados ao problema: o porte e a diversidade do mercado de jogos; a variedade de configurações de computadores; a dependência do desempenho em relação ao equipamento e à carga de trabalho; e a dificuldade de transformar dados técnicos em decisões de uso. Os estudos de RAG e diagnóstico acrescentam abordagens relacionadas a explicações contextualizadas e análise iterativa, mas não são técnicas empregadas na implementação. A contribuição investigada pelo Roda Liso consiste em avaliar um fluxo que observa o FPS, recomenda um preset e executa a alteração mediante confirmação, com possibilidade de restauração. Sua eficácia ainda precisa ser verificada nas condições previstas.

Essa delimitação orienta duas etapas de avaliação planejadas. A verificação funcional examinará se o agente respeita seus critérios de acionamento, seleção e aplicação. A comparação antes e depois examinará o FPS e as mudanças visuais decorrentes do preset no mesmo cenário. Os limiares da regra, os intervalos de monitoramento e os períodos de espera são parâmetros da implementação, cuja adequação será examinada nos testes; os artigos citados não validam esses valores. Enquanto não houver medições realizadas e descritas, não se afirmarão ganhos de desempenho, melhoria de compreensão do usuário ou superioridade em relação às soluções da literatura.

3 Metodologia

A pesquisa é aplicada e exploratória e prevê a avaliação técnica do protótipo Roda Liso. O objetivo é verificar o comportamento do agente conforme sua implementação atual: detectar uma queda sustentada de FPS, selecionar um preset gráfico já cadastrado e aplicar a alteração após a confirmação do usuário. O protocolo também prevê comparar o desempenho e a qualidade visual antes e depois da aplicação. Trata-se de um plano de avaliação; os procedimentos descritos ainda não representam resultados obtidos.

3.1 Delineamento e etapas da avaliação

A avaliação será organizada em duas etapas. Na primeira, serão verificados o gatilho de FPS, a seleção do preset, a explicação apresentada ao usuário e os mecanismos de confirmação, backup e reversão. Na segunda, será comparado o jogo com a configuração gráfica inicial e com o preset aplicado pelo agente, mantendo-se o mesmo computador e cenário. Essa separação evita que o monitoramento automático altere a configuração durante a captura usada na comparação.

3.2 Funcionamento do agente avaliado

O PresentMon registra os tempos entre quadros apresentados pelo jogo. O agente calcula o FPS em janelas de aproximadamente dois segundos. A meta padrão é 30 FPS e pode ser alterada pelo usuário. Uma recomendação só é iniciada quando o FPS permanece abaixo da meta por dez segundos consecutivos, respeitado o atraso inicial de 120 segundos após a detecção do jogo. Depois de cada ciclo, há um período de espera de 120 segundos antes de um novo ciclo.

O déficit percentual corresponde à diferença entre o FPS-alvo e o FPS medido, dividida pelo FPS-alvo e multiplicada por 100. A função máx(0, x) limita o valor mínimo a zero:

$$\text{Déficit (\%)} = \text{máx}(0, ((\text{FPS-alvo} - \text{FPS medido}) \div \text{FPS-alvo}) \times 100)$$

Uma regra programada em Python escolhe entre os presets existentes usando o déficit e a qualidade gráfica identificada. O modelo openai/gpt-oss-20b é acessado pela integração ChatGroq do LangChain na plataforma Groq, com temperatura 0,2, e redige uma explicação curta. O modelo não escolhe o preset nem cria opções gráficas. A seleção é feita pela regra Python e depende da confirmação do usuário para ser aplicada.

3.3 Jogos reconhecidos e identificação da qualidade

O monitoramento em tempo real atua sobre os jogos cadastrados em PROCESSOS_JOGOS: The Witcher 3 (witcher3.exe), Cyberpunk 2077, CS 2, GTA V e Red Dead Redemption 2. No The Witcher 3, a qualidade é inferida a partir da opção TextureQuality do arquivo de configuração, o que não confirma o nível de todas as opções gráficas. Nos demais jogos, quando a qualidade não é reconhecida, o sistema utiliza “Médio”

como padrão. Por esse motivo, o teste controlado principal priorizará The Witcher 3; outro jogo só será incluído após a verificação de que o preset e a configuração são identificados corretamente.

A regra Python e a instrução textual enviada ao modelo divergem em um caso: para qualidade Alta e déficit entre 20% e menos de 35%, o código seleciona "Nível 3 — Normal", enquanto o prompt orienta o modelo a preferir "Nível 2 — Baixo". O protocolo registrará separadamente o preset selecionado e a frase apresentada. A expressão "seleção esperada" refere-se à saída prevista pela regra Python; não afirma que esse preset melhorará o desempenho.

Quadro 2 – Regra programada para seleção do preset

Qualidade detectada	Déficit menor que 20%	Déficit de 20% a menos de 35%	Déficit igual ou maior que 35%
Baixo	Nível 1 — Mais Baixo	Nível 1 — Mais Baixo	Nível 1 — Mais Baixo
Médio ou desconhecido	Nível 3 — Normal	Nível 2 — Baixo	Nível 1 — Mais Baixo
Alto ou Ultra	Nível 3 — Normal	Nível 3 — Normal	Nível 1 — Mais Baixo

Fonte: elaboração própria, conforme a regra implementada no agente.

3.4 Equipamento e condições de teste

Será utilizado um computador de mesa com processador Intel Core i5-4590, placa de vídeo NVIDIA GeForce GTX 950, 16 GB de memória RAM DDR3 e sistema operacional Windows 10. Antes da coleta, serão registrados a versão e o build do Windows, o driver gráfico, o modelo e a memória de vídeo da placa, a placa-mãe, o tipo e a capacidade do armazenamento, a velocidade e o modo de operação da memória, o perfil de energia, a resolução, a versão do jogo e as opções gráficas utilizadas. O tipo e a capacidade do armazenamento serão registrados para caracterizar o computador, mas não serão analisados como variáveis explicativas do FPS.

O piloto fixará uma resolução, uma versão do jogo e um cenário reproduzível, como um benchmark interno ou um mesmo arquivo salvo com percurso definido. A proposta inicial é usar resolução de 1920 × 1080, com V-Sync e limitadores de FPS desligados, se isso for compatível com o cenário selecionado. Caso algum parâmetro precise ser alterado no piloto, a mudança será registrada e mantida em todas as condições comparadas.

As medições serão feitas no mesmo local, com gabinete e ventilação na mesma posição. O computador será reiniciado e aguardará cinco minutos antes da sessão; aplicativos, downloads e sincronizações desnecessários serão encerrados. A temperatura ambiente será registrada quando houver instrumento disponível. Não serão instaladas atualizações nem alterados drivers durante a coleta. O PresentMon será executado com as permissões exigidas pelo Windows, e sua versão e forma de execução serão anotadas.

3.5 Verificação funcional do gatilho e da recomendação

Serão testados dois cenários para verificar o acionamento. No primeiro, a meta será igual ou inferior ao FPS observado; o agente deverá permanecer sem recomendar enquanto as leituras válidas estiverem na meta ou acima dela. No segundo, será definida uma meta superior ao FPS observado; após o atraso inicial de 120 segundos, será verificado se a recomendação ocorre somente depois de dez segundos consecutivos

abaixo da meta. Os cenários serão executados em rodadas separadas ou respeitando o cooldown de 120 segundos.

Em cada recomendação, serão anotados o jogo, FPS medido, FPS-alvo, déficit, qualidade identificada, preset selecionado, explicação apresentada e decisão do usuário. Também será verificado se o jogo é encerrado e reiniciado durante a aplicação, se o arquivo original é copiado para backup e se a reversão restaura a configuração anterior. Será incluído um teste para qualidade Alta e déficit de 20% a menos de 35%; nessa condição, a regra Python prevê "Nível 3 — Normal". O grupo comparará esse resultado com a explicação gerada pelo modelo e registrará eventual divergência.

3.6 Comparação de desempenho antes e depois

A condição A corresponderá à configuração gráfica inicial. A condição B corresponderá à configuração após a aplicação do preset recomendado. Antes de cada condição, será restaurado o arquivo original. Em A, o jogo será executado com o agente fechado. Em B, o agente será ativado e a recomendação confirmada; após o reinício do jogo, o aplicativo Roda Liso será encerrado para parar o monitoramento. O piloto verificará que fechar o Roda Liso não encerra o jogo.

Em ambas as condições serão mantidos o mesmo computador, jogo e versão, cenário, resolução, percurso, perfil de energia e opções gráficas que não forem alteradas pelo preset. O cenário será aquecido por dez minutos com o agente fechado e, em seguida, será capturado por 180 segundos com o PresentMon, salvando-se o CSV bruto em pasta própria. Serão realizados três pares, alternando as ordens A–B, B–A e A–B. A configuração inicial será restaurada antes de cada medição, inclusive antes de cada execução B.

Para cada captura, o FPS médio será calculado pela quantidade de intervalos de quadro válidos dividida pela soma desses intervalos em segundos. Os arquivos brutos e os valores de cada repetição serão preservados. As janelas de aproximadamente dois segundos usadas pelo agente servirão para avaliar o gatilho; a comparação A/B utilizará as capturas contínuas de 180 segundos. Percentil 99 do tempo de quadro e 1% low não serão tratados como métricas calculadas pelo agente, pois a rotina atual não os produz.

3.7 Critérios de análise e limitações

A análise será descritiva. Serão apresentados os valores de cada captura, as médias de FPS em A e B e as diferenças observadas em cada par. Também serão registrados se o jogo inicia, carrega e conclui o cenário, erros ou travamentos, mudanças visuais nas mesmas cenas e o funcionamento da confirmação, do backup e da reversão. Resultados sem melhora, presets repetidos, falhas da chamada à Groq ou divergências entre a frase e o preset aplicado serão relatados.

Os períodos de cinco minutos, aquecimento de dez minutos, captura de 180 segundos e três pares são parâmetros iniciais a confirmar no ensaio piloto. Como a avaliação será feita em um computador e terá como foco principal um jogo, as conclusões serão limitadas às condições testadas e não permitirão generalizações para outros computadores ou jogadores. O agente atual usa presets predefinidos e não utiliza CPU, GPU, RAM ou VRAM para decidir a recomendação; essas métricas, embora monitoradas, não serão tratadas como causas avaliadas pelo estudo.

Referências

BUIJSMAN, Michiel. Global games revenue cracked $200 billion in 2025. Newzoo, 18 jun. 2026. Disponível em: https://newzoo.com/articles/global-games-market-2025. Acesso em: 23 out. 2026.

GERRA, Ayush Rakesh; JOSEPH, Richard. GameSpec Advisor: tool to suggest PC specifications. [S. l.: s. n.], 2026. 14 p. Manuscrito em PDF consultado. Disponível em: https://journal.uob.edu.bh/bitstreams/f47af445-6785-4995-a76f-4e45684361fb/download. Acesso em: 23 out. 2026.

KAPOOR, Vishaal et al. DQA: diagnostic question answering for IT support. In: ANNUAL MEETING OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS, 64., 2026, San Diego. Proceedings [...] Industry Track. [S. l.]: Association for Computational Linguistics, 2026. p. 1128–1135. DOI: 10.18653/v1/2026.acl-industry.79.

LOPEZ, Leonardo; GUYNN, Michael; LU, Meiliu. Predicting computer performance based on hardware configuration using multiple neural networks. In: IEEE INTERNATIONAL CONFERENCE ON MACHINE LEARNING AND APPLICATIONS (ICMLA), 17., 2018. Proceedings […]. IEEE, 2018. p. 824–827. DOI: 10.1109/ICMLA.2018.00132.

MANKODI, Amit; BHATT, Amit; CHAUDHURY, Bhaskar; KUMAR, Rajat; AMRUTIYA, Aditya. Evaluating machine learning models for disparate computer systems performance prediction. In: IEEE INTERNATIONAL CONFERENCE ON ELECTRONICS, COMPUTING AND COMMUNICATION TECHNOLOGIES (CONECCT), 2020. Proceedings […]. IEEE, 2020.

PASHKOV, Savelii. Video game industry market analysis: approaches that resulted in industry success and high demand. 2021. Trabalho de conclusão de curso (International Business Administration) – Vaasan Ammattikorkeakoulu, University of Applied Sciences, 2021.

STANDARD PERFORMANCE EVALUATION CORPORATION (SPEC). SPEC CPU2017 overview / what's new? Versão de 3 set. 2024. Disponível em: https://www.spec.org/cpu2017/Docs/overview.html. Acesso em: 23 out. 2026.

VALVE. Steam Hardware & Software Survey: September 2026. Steam, set. 2026. Disponível em: https://store.steampowered.com/hwsurvey/. Acesso em: 23 out. 2026.

XU, Zhentao et al. Retrieval-augmented generation with knowledge graphs for customer service question answering. In: INTERNATIONAL ACM SIGIR CONFERENCE ON RESEARCH AND DEVELOPMENT IN INFORMATION RETRIEVAL, 47., 2024, Washington, DC. Proceedings [...]. New York: ACM, 2024. DOI: 10.1145/3626772.3661370.

YUN, Juwon; LEE, Jinyoung; KIM, Cheong Ghil; LIM, Yeong-Kyu; NAH, Jae-Ho; KIM, Youngsik; PARK, Woo-Chan. A novel performance prediction model for mobile GPUs. IEEE Access, [S. l.], v. 6, p. 16235–16245, mar. 2018. DOI: 10.1109/ACCESS.2018.2816040. Disponível em: https://ieeexplore.ieee.org/document/8316820. Acesso em: 23 out. 2026.

ZHANG, Zhongyang et al. Predicting quality of video gaming experience using global-scale telemetry data and federated learning. Proceedings of the ACM on Human-Computer Interaction, v. 9, n. 6, art. GAMES012, 2025. DOI: 10.1145/3748607.